Алгоритм очистки и верификации трафика (Traffic Anomaly Detection)

Суть задачи:

Датчики подсчета посетителей ('Счетчик Посетителей'[Кол-во посетителей среднее]) подвержены техническим сбоям (блокировка сенсора, тени, “фантомные” входы) и аномалиям. Однако данные о продажах ('Продажа'[Кол-во Чеков]) являются финансово подтвержденной истиной.

Мы внедряем алгоритм “Sale-Validated Traffic”.

Алгоритм сравнивает показания датчиков с “Ожидаемым трафиком” (рассчитанным на основе чеков через регрессионную модель).

Если расхождение небольшое (окно “Window Shoppers”) – мы верим датчику.

Если расхождение статистически невозможно (например, 100 чеков, но 5 человек) – мы помечаем это как сбой и заменяем данные на расчетные.

Для выявления сбоев используется метод Робастной Статистики (Robust Statistics), который устойчив к естественным выбросам и позволяет отличать реальные толпы людей от поломок оборудования.

Архитектурные требования (Важно!)

Принцип неразрушающего контроля:

Исходные данные неприкосновенны: Существующее поле 'Счетчик Посетителей'[Кол-во посетителей среднее] (сырые данные с датчиков) должно остаться в хранилище данных (DWH) без изменений. Оно необходимо для исторического анализа и аудита.

Новая метрика: Алгоритм должен формировать новое расчетное поле: Adjusted_People.

Шаги:

Шаг 1

Создать представление/таблицу в хранилище данных (DWH), содержащую **исключительно** эти поля.

Примечание: 'Фирма'[LFL], 'Фирма'[Код] – Code; 'Дата'[Дата] – Date; 'Час'[Час] – Hour; 'Счетчик Посетителей'[Кол-во посетителей среднее] – People; 'Продажа'[Кол-во Чеков] – Receipts.

Итоговый набор данных для модели содержит только следующие столбцы:

- People;
- Date
- Month;
- Day_of_week;
- Week_number;
- Hour;
- Receipts;
- Code.

Входные данные (Таблица коэффициентов):
Бизнес-анализ (БА) предоставляет таблицу Model_Coefficients со следующей структурой (см. скриншот):

Term	Coefficient	Model_Type
(Intercept)	3.987125233	LFL_Specific
Month	0.31544158	LFL_Specific
Day_of_week	0.104651279	LFL_Specific
Week_number	-0.07974508	LFL_Specific
Hour	-0.10000911	LFL_Specific
Receipts	1.410638347	LFL_Specific
CodeEKB02	-2.375167778	LFL_Specific
CodeMSK01	0.318068457	LFL_Specific
CodeMSK02	-1.944364041	LFL_Specific
CodeMSK27	-0.704474844	LFL_Specific
CodeMSK73	-0.759371981	LFL_Specific
CodeMSK74	-0.269796822	LFL_Specific
CodeMSK75	-2.193497924	LFL_Specific
CodeMSK76	-1.521993022	LFL_Specific
CodeMSK77	-0.043373891	LFL_Specific
CodeMSK78	-0.736215049	LFL_Specific
CodeMSK79	-1.684411112	LFL_Specific
CodeMSK80	-0.945718243	LFL_Specific
CodeSPB09	-2.538469224	LFL_Specific
CodeSPB10	-1.206445669	LFL_Specific
CodeSPB11	-2.326916467	LFL_Specific
CodeSPB12	-0.812659709	LFL_Specific
CodeSPB13	-2.29643201	LFL_Specific
CodeTMN01	-1.253667905	LFL_Specific
CodeTMN02	-1.726544199	LFL_Specific
CodeTMN03	0.548175391	LFL_Specific
(Intercept)	3.809982667	NewStore_Global
Month	0.244692065	NewStore_Global
Day_of_week	0.062683722	NewStore_Global
Week_number	-0.065587657	NewStore_Global
Hour	-0.142727376	NewStore_Global
Receipts	1.525072916	NewStore_Global

- Term: Название переменной (например, Month, Receipts, CodeMSK01).
- Coefficient: Числовое значение.
- Model_Type: Флаг типа модели (LFL_Specific или NewStore_Global).

Логика выбора модели:
Перед расчетом для каждой торговой точки (Code) система должна определить, является ли она "исторической" (LFL) или "новой":

1. **LFL (Like-for-Like):** Если для данного Code существует персональный коэффициент в таблице (например, CodeMSK01), применяем логику **LFL**.
2. **New Store:** Если персонального коэффициента нет, применяем логику **NewStore_Global**.

Формула расчета:

Система должна использовать условную логику (CASE WHEN) или Join-логику для выбора правильных коэффициентов.

ВАРИАНТ А: Если магазин LFL (есть в списке):
Используем коэффициенты, где Model_Type = 'LFL_Specific'.

```
People_Regress =
Intercept_LFL
+ (Coef_Month_LFL * Month)
+ (Coef_Day_LFL * Day_of_week)
+ (Coef_Week_LFL * Week_number)
+ (Coef_Hour_LFL * Hour)
+ (Coef_Receipts_LFL * Receipts)
+ Coef_Code_Specific  <-- (Персональная поправка, напр. значение для CodeMSK01)
```

ВАРИАНТ Б: если магазин Новый (нет в списке):
Используем коэффициенты, где Model_Type = 'NewStore_Global'.
(Обратите внимание: коэффициенты сезонности здесь отличаются от LFL, а персональная поправка отсутствует).

```
People_Regress =
Intercept_Global
+ (Coef_Month_Global * Month)
+ (Coef_Day_Global * Day_of_week)
+ (Coef_Week_Global * Week_number)
+ (Coef_Hour_Global * Hour)
+ (Coef_Receipts_Global * Receipts)
(Персональная поправка = 0)
```

Финальное действие:
Результат People_Regress следует округлить вверх до целого числа (CEILING).

Шаг N 2. Выявление выбросов.

Бизнес-требование: алгоритм выявления аномалий трафика

Цель: Проведение постмодельной валидации прогнозных значений трафика: расчёт Z-score и идентификация статистических аномалий.

Шаг 2.1. Применение «жёстких» логических правил (предварительная обработка)

Перед статистическим анализом определяем базовое значение Adjusted_People:

- Если конверсия> 100 % (признак сбоя датчика)
  → **People_regress**
- Иначе, если People = 0 **и** Receipts > 0
  → **People_regress**
- В остальных случаях
  → используем **People**

См. скриншот

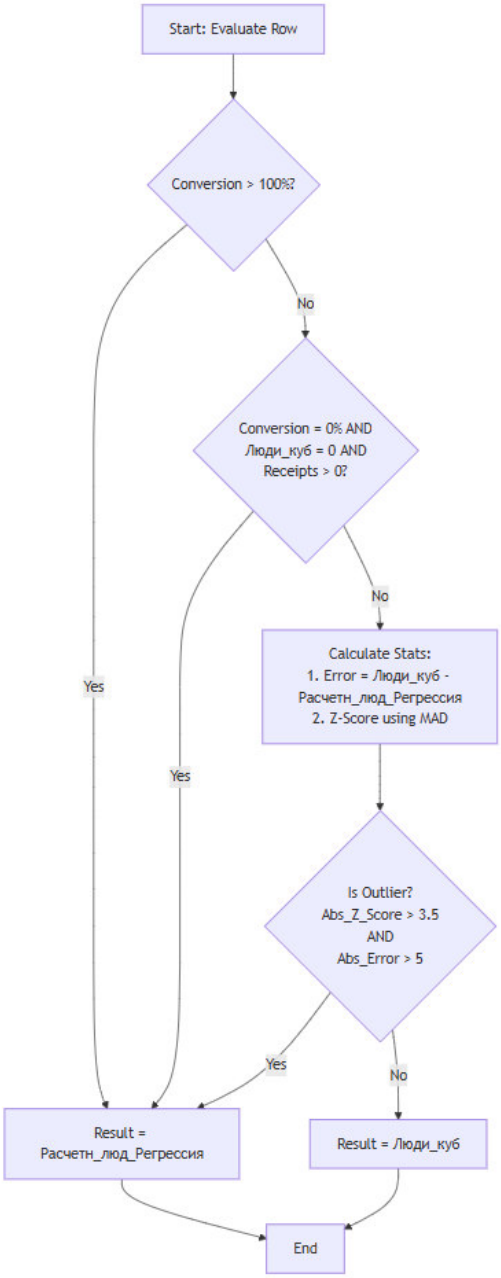

Шаг 2.2. Определение группировки (детализация)

Рассчитываем статистику по следующим группам:

- Группировка по: Store_Code, Month, Day_of_Week, Hour.

Примечание: такая группировка позволяет сравнивать, например, «понедельники в 10:00 утра в декабре» между собой.

Шаг 2.3. Расчёт устойчивых статистических показателей (по группам)

Для каждой группы рассчитываем следующие метрики на основе ошибки (Adjusted_People - People_regress):

1. **Median_Error** – медиана ошибок.
2. **MAD** (медианное абсолютное отклонение):
   Формула:

Median(ABS(Error – Median_Error)) × 1,4826

1. **Effective_MAD** (защитный механизм):
   - Если MAD = 0, то **2,5**, иначе – значение MAD.
     Примечание: 2,5 – минимально допустимая величина волатильности.
2. **Modified_Z_Score** (модифицированный Z-показатель):
   Формула:

   (Error – Median_Error) / Effective_MAD

Шаг 2.4. Выявление выбросов и замена значений

Строка признаётся выбросом, если **одновременно** выполняются **оба** условия:

1. **Статистическая редкость:**

   Modified_Z_Score>3,5

2. **Бизнес-значимость:**

   |Error|>12

Примечание: порог 12 предотвращает маркировку как выброса небольших групп «прохожих у витрины».

Финальная логика (Колонка**Traffic_Finalized)**:

ЕСЛИ строка помечена как статистический выброс (Is_Outlier = TRUE)

ТО: использовать значение регрессионной модели (People_regress).

ИНАЧЕ (строка статистически нормальна)

ТО: использовать значение из Шага 2.1 (Adjusted_People).