Техническое задание:

Преамбула к бизнес-функциональным требованиям (БФТ):

Важно:

Исходные данные неприкосновенны: Существующее поле 'Счетчик Посетителей'[Кол-во посетителей среднее] (сырые данные с датчиков) должно остаться в хранилище данных (DWH) без изменений.
Новая метрика: Алгоритм должен формировать новое расчетное поле: Adjusted_People.

Временные рамки применения:

Настоящая инструкция применяется для текущего отчётного года (2026) и всех последующих отчётных периодов.

Для предыдущих отчётных периодов:

- 2024 год;
- 2025 год

- в качестве исходных данных должны использоваться результаты модельных расчётов (Моделирование) по методологии (регрессионная модель + робастная статистика). IT-отдел получит от инициатора требований структурированный CSV-документ.

Данный расчет для типа точек **LFL**.

Каскадный алгоритм восстановления трафика (усреднение с учетом YoY тренда)

1. Цель и архитектура алгоритма

Цель алгоритма - восстановить значения трафика (People) в дни, когда аппаратные датчики работали некорректно. Вместо усреднения по типу точки (локация), алгоритм использует иерархическую (каскадную) систему бенчмарков самого магазина, опираясь исключительно на очищенные исторические данные, и корректирует их на межгодовой тренд (Year-over-Year Drift), рассчитанный с помощью робастных статистических методов.

2. Базовые переменные и определения (Препроцессинг)

Для каждого магазина (Code) и дня (Date) определяются базовые величины:

- Y = Фактический трафик (People) за день.
- X = Фактическое количество чеков (Receipts) за день.
- CR = $\frac{X}{Y}$ (Фактическая дневная конверсия)

2.1. Индикатор «Чистых данных»

Для обучения бенчмарков используются **только** данные, очищенные от программных и аппаратных сбоев. День признается "Чистым" ($I_{clean} = 1$), если выполняются бизнес условия: исключаем конверсию ниже 9% (фантомный трафик) и выше 90% (недоучет трафика))

$$I_{clean} = \begin{cases} 1, if\ 0.09 < CR < 0.90 \\ 0, otherwise \end{cases}$$

2.2. Индикатор «Аномалии»

День требует восстановления ($I_{anomaly} = \begin{cases} 1, if\ (CR > 1.0)\ OR\ (Y = 0\ and\ X > 0)\ OR (CR = null) \\ 0, otherwise \end{cases}$

3. Расчет исторических бенчмарков

Для каждого магазина вычисляются три уровня исторических эталонов конверсии. Для расчета используются суммы, а не средние значения дробей.

Уровень 1: Историческое окно 4 недель (H_{4w})
Конверсия за аналогичный день недели за предыдущие 28 дней:

$H_{4w} = \frac{\sum_{i=1}^{4} X_{t-7i}}{\sum_{i=1}^{4} Y_{t-7i}}$, где $I_{clean}(t-7i) = 1$

Уровень 2: Узкий бенчмарк (B_{spec})
Средняя конверсия для данного Магазина, в данный Месяц, в данный День недели за всю историю:
$B_{spec} = \frac{\sum X}{\sum Y}$ для (кода точки, месяца, дня недели) при $I_{clean} = 1$

Уровень 3: Широкий бенчмарк (B_{broad})
Средняя конверсия для данного Магазина в данном Месяце (без учета дня недели):

$B_{broad} = \frac{\sum X}{\sum Y}$ для (кода точки, месяца) при $I_{clean} = 1$

4. Оценка межгодового тренда (Асимметричный доверительный интервал)

Поскольку уровни 2 и 3 (B_{spec}, B_{broad}) могут включать данные прошлых лет, их необходимо скорректировать на тренд роста/падения магазина (YoY Trend). Из-за эксцесса и асимметрии в данных ритейла используется **Разложение Корниша-Фишера.**

Шаг 4.1. Разница конверсий (Delta)
Для каждого дня магазина вычисляется прирост к прошлому году:

$$\Delta CR = CR_{curr\ year} - CR_{prev\ year}$$

Шаг 4.2. Робастный центр распределения ($AdjCenter_{CF}$)

Для пула ΔCR за месяц рассчитываются: Среднее (μ), Стандартная ошибка (SE), Асимметрия (S) и Эксцесс (K).
Скорректированные квантили нормального распределения (Z_{adj}) при 95% вероятности рассчитываются как:
$*Z_{adj} = Z + \frac{(Z^2-1)S}{6} + \frac{(Z^3-3Z)K}{24} - \frac{(2Z^3-5Z)S^2}{36}$

Вычисляется асимметричный доверительный интервал (LCL, UCL), и его середина принимается за истинный тренд магазина за месяц:

$$LCL_{CF} = \mu - Z_{adj} \times \mathrm{SE}$$

$$UCL_{CF} = \mu + Z_{adj} \times \mathrm{SE}$$

$$AdjCenter_{CF} = \frac{LCL_{CF} + UCL_{CF}}{2}$$

Шаг 4.3. Ежедневный поправочный коэффициент (K_{trend})
Так как $AdjCenter_{CF}$ – это суммарный тренд месяца, для корректировки ежедневных бенчмарков он распределяется по дням:

$$K_{trend} = \frac{AdjCenter_{CF}}{Days\ in\ month}$$

5. Финальная Каскадная Логика (Дерево решений)

Итоговое расчетное количество посетителей (Y_{final}) вычисляется построчно. Алгоритм спускается по каскаду "сверху вниз", пока не найдет первый доступный бенчмарк (не равный null).

$$Y_{final} = \begin{cases} Y, if\ I_{anomaly} = 0\ (\text{Данные корректны}) \\ Y, if\ Y = 0\ OR\ X = 0\ (\text{Магазин закрыт или Трафика нет}) \\ \left\lceil \frac{X}{H_{4w}} \right\rceil, if\ H_{4w} \neq null\ (\text{Используем историю последних 4 недель}), \\ \left\lceil \frac{X}{B_{spec}+K_{trend}} \right\rceil, if\ B_{spec} \neq null\ (\text{Узкий бенчмарк + поправка на тренд}) \\ \left\lceil \frac{X}{B_{broad}+K_{trend}} \right\rceil, if\ B_{broad} \neq null\ (\text{Широкий бенчмарк + поправка на тренд}) \end{cases}$$

(Функция $\lceil \ldots \rceil$ *обозначает округление вверх до ближайшего целого человека*).

* В теории вероятностей:

- 1-й момент: среднее μ
- 2-й момент: дисперсия;
- 3-й момент: асимметрия (коэффициент асимметрии);
- 4-й момент: эксцесс (коэффициент эксцесса).

Следовательно, в знаменателе в формуле используются соответствующие коэфф.

- 6 - потому что асимметрия – это 3-й момент.
  - 3! (3-факториал) =3×2×1=6.
- 24 - потому что эксцесс – это 4-й момент.
  - 4! (4-факториал) =4×3×2×1=24.
- 36 - потому что в последнем члене возводится в квадрат асимметрия (S^2).
  - Это взаимодействие 3-го момента с самим собой: 6×6=36.

Пример расчета асимметричного доверительного интервала представлен в файле ‘Дов интервал коэф’.

Точки типа LFL = нет

Кол-во Чеков / Конверсия по винотекам того же типа расположения (поле Расположение - БЦ, ЖК, Рынок, Стрит, ТЦ), по которым Конверсия рассчитана корректно (принимает значения от 0% до 100%) – пример расчета 2.

3.2 Пример расчета *2*.
Если за 4 последних недели данные по конверсии отсутствуют или конверсия превышает 100% и не может быть пересчитана по логике, описанной выше, то рассчитываем Конверсию по описанию в условии №3.

Предположим, 05.07.2025 по какой-то винотеке (тип расположения - БЦ) конверсия отсутствует. Ее новым значением должно быть значение Конверсии, рассчитанное по формуле [Суммарное Кол-во чеков по винотекам БЦ с корректной конверсией (0% до 100%) / Суммарный трафик (Кол-во посетителей среднее) по винотекам БЦ с корректной конверсией].

2. Создать показатель Достроенная конверсия = Кол-во Чеков / Достроенный трафик.

Оба новых показателя должны рассчитываться в тех же разрезах, что и показатели Кол-во посетителей среднее и Конверсия.
Исключение: для новых показателей (Достроенный трафик и Достроенная конверсия) не требуется детализация по часам. Только по дням.
Показатели Кол-во посетителей среднее и Конверсия оставляем без изменений.